

Exploração de Redes Neurais para Classificação de imagens de Galáxias

Nicolý Rodrigues da Costa
Thamara Medeiros
Inayê Melo
Deyvisson Garcês
Eduardo Cherobin Martins

Galáxias

- Uma galáxia é um sistema massivo, gravitacionalmente ligado, de estrelas, que pode também incluir remanescentes estelares (anãs brancas, estrelas de nêutrons, buracos negros), gás e poeira, bem como matéria escura não bariônica.



Figura 1. Galáxia do Galaxy10 Decals

Galáxias

- A estrutura das galáxias é uma das formas fundamentais pelas quais as propriedades de galáxias são descritas e pelas quais a evolução das galáxias é inferida.
 - Idade
 - Taxa de formação de estrelas
 - Histórico de interações e fusões

- Número de galáxias observáveis é 2×10^{12}



Figura 1. Galáxia do Galaxy10 Decals

Base de dados

Galaxy10 DECaLS – Visão Geral

- Dataset com **quase 18 mil imagens** de galáxias.
- Imagens em **cores (RGB)** com resolução **256×256 pixels**.
- Composto por imagens **rigorosamente filtradas** e classificadas pelo projeto **Galaxy Zoo (GZ)**.

Projeto Galaxy Zoo

- Projeto colaborativo com **voluntários** classificando galáxias.
- Contém aproximadamente **441 mil galáxias** rotuladas.
- Classificação em **10 classes morfológicas**, considerando:
 - Presença de **braços espirais**
 - Presença de **barra central**
 - **Disco galáctico**
 - Outras características estruturais

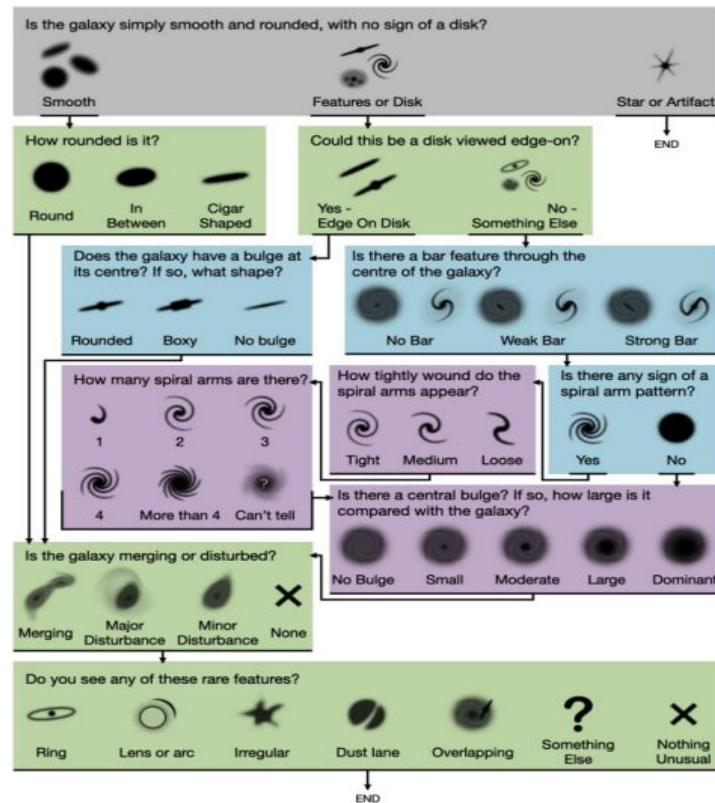


Figura 2. Árvore de Decisão do Galaxy Zoo. (Leung, 2018)

Base de dados




Figura 3. Exemplos de imagens do Galaxy10-DECaLS das diferentes classes do conjunto de dados.

Base de dados




Gráfico 1. Quantitativo de imagens das galáxias por classe.

Tarefa

Classificação de imagens de galáxias em 10 classes com base em características morfológicas.

Arquiteturas utilizadas

- CNN Tradicional
- Resnet 50
- BYOL

Pré-processamento

- Divisão do dataset: 80% Treino, 5% Validação e 15% Teste

CNN




Figura 4. Representação da CNN utilizada

Testes Realizados

- **Quantidade de convoluções:** nas primeiras versões, estávamos com apenas 3 camadas convolucionais, ajustamos ao longo do treino para 5 camadas convolucionais.
- **Estrutura das camadas:** as primeiras versões da rede estavam com camadas lineares muito grandes, gerando muitos parâmetros treináveis e dificultando o treino. Aumentamos a profundidade da rede para melhorar diminuindo as camadas lineares.
- **Learning rate:** começamos com um learning rate muito alto e depois diminuimos, melhorando o treino.
- **Dropout:** começamos com o dropout muito baixo e ajustamos depois.

CNN

Random Crop: O problema do corte aleatório como Data Augmentation no nosso dataset



Foram aplicados outros augmentations como ColorJitter, GaussianBlur, HorizontalFlip, VerticalFlip, Rotation

Figura 5. Representação do Random Crop

CNN



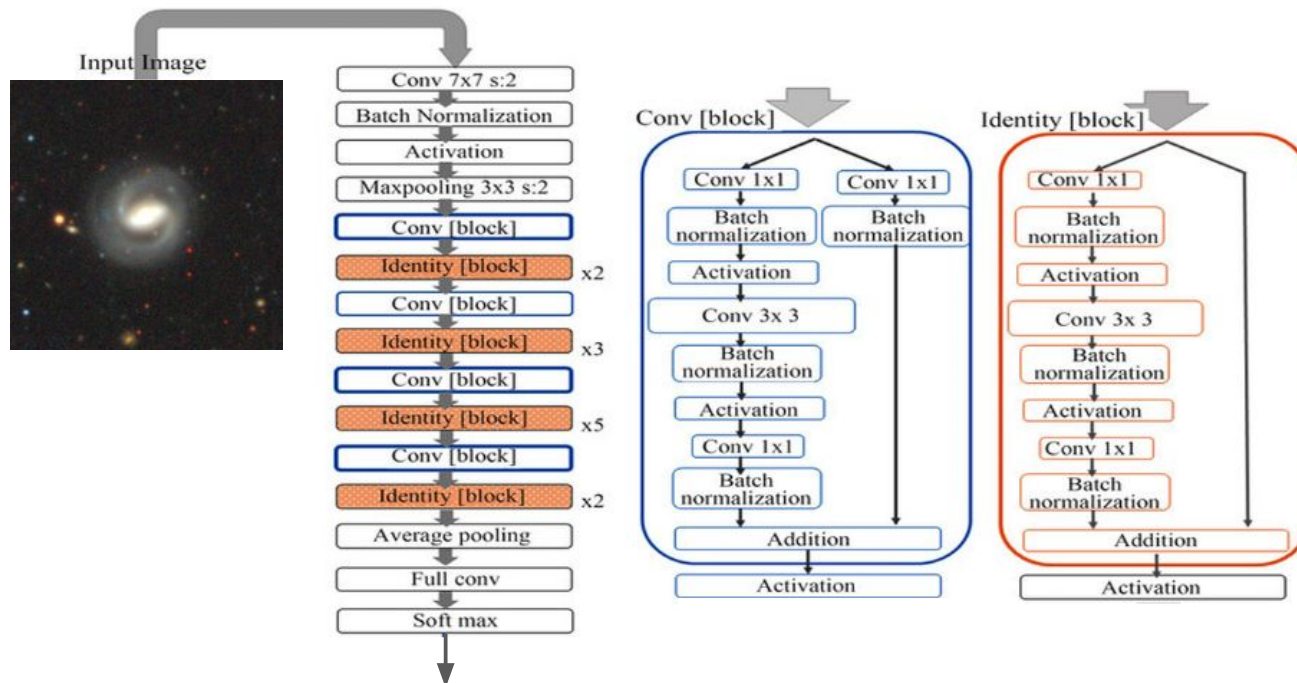


Gráfico 2 e 3. Loss e Acurácia dos conjuntos de treino e validação da CNN

Tempo de treino: 35 minutos

ResNet-50



Class 5: Barred Spiral Galaxies

Figura 6. Representação esquemática do ResNet-50 (2015, Kaiming He et al.)

ResNet-50

- com data augmentation

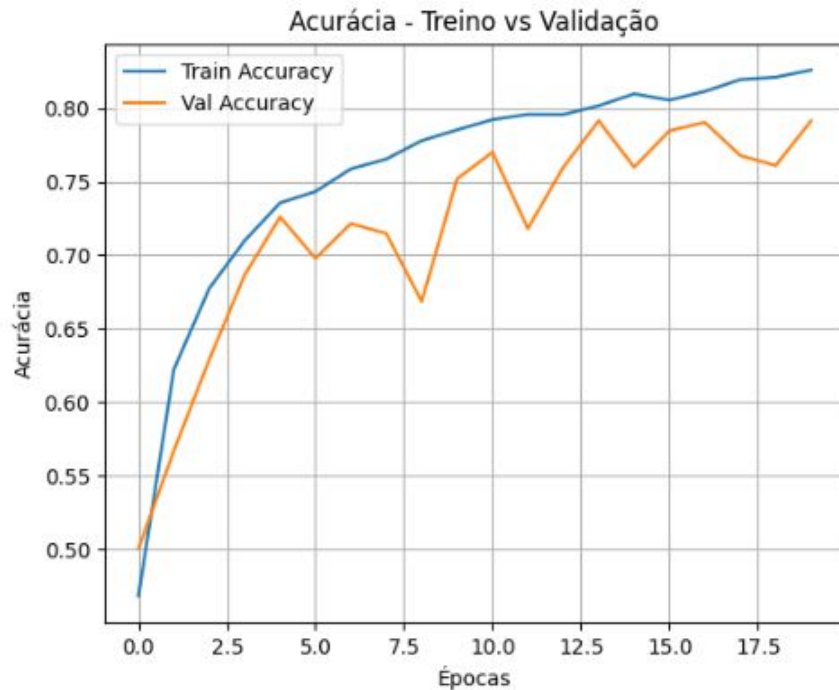
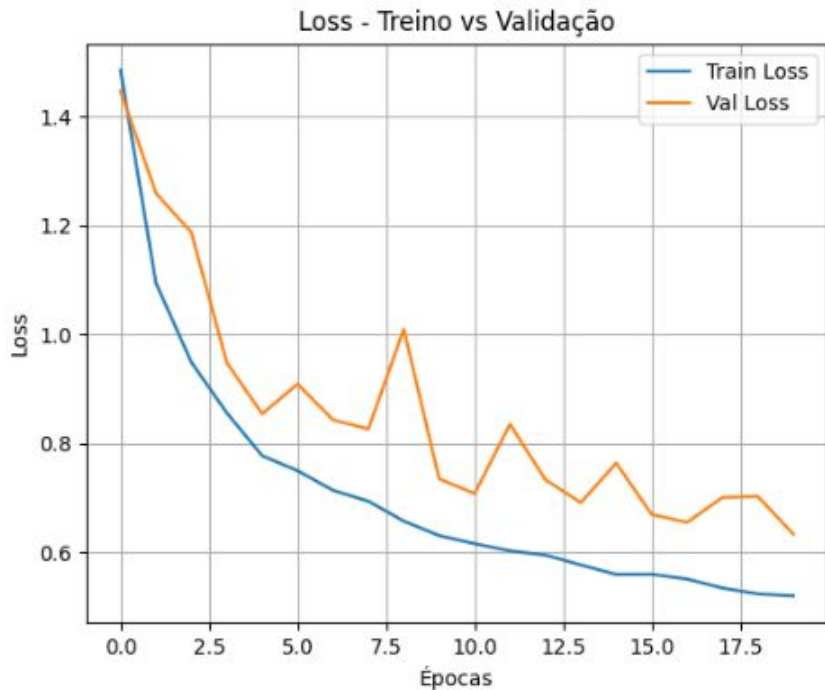




Gráfico 4 e 5. Loss (1) e Acurácia (2) dos conjuntos de treino e validação da Resnet-50, com data augmentation

Tempo de treino: 1 hora e 30 minutos

ResNet-50

- sem data augmentation



Gráficos 6 e 7. Loss (1) e Acurácia (2) dos conjuntos de treino e validação da Resnet-50, sem data augmentation

BYOL

Bootstrap Your Own Latent é um método de aprendizado auto supervisionado introduzido em 2020 (Grill et al. 2020). O Encoder usado foi a ResNet-50 pré-treinada no ImageNet e as imagens foram diminuídas a 128x128.

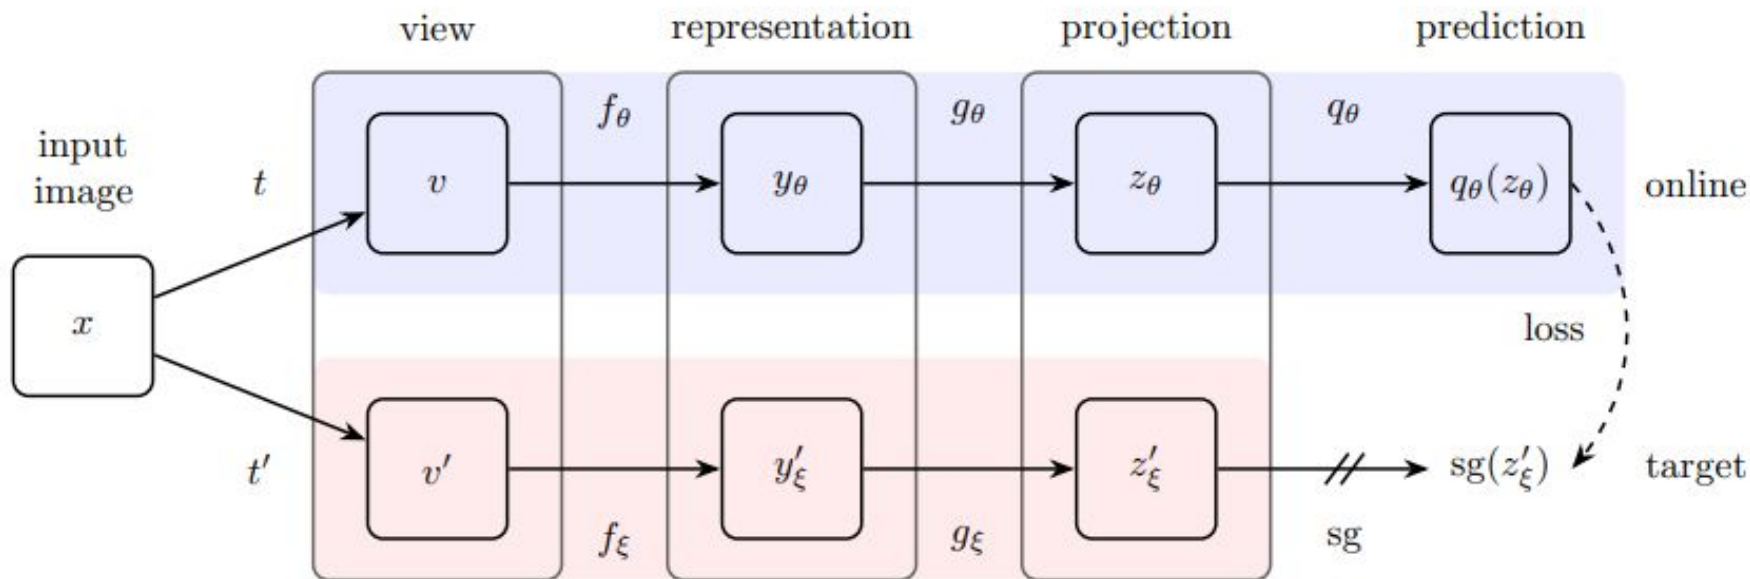


Figura 7. Arquitetura BYOL (Grill et al. 2020).

BYOL

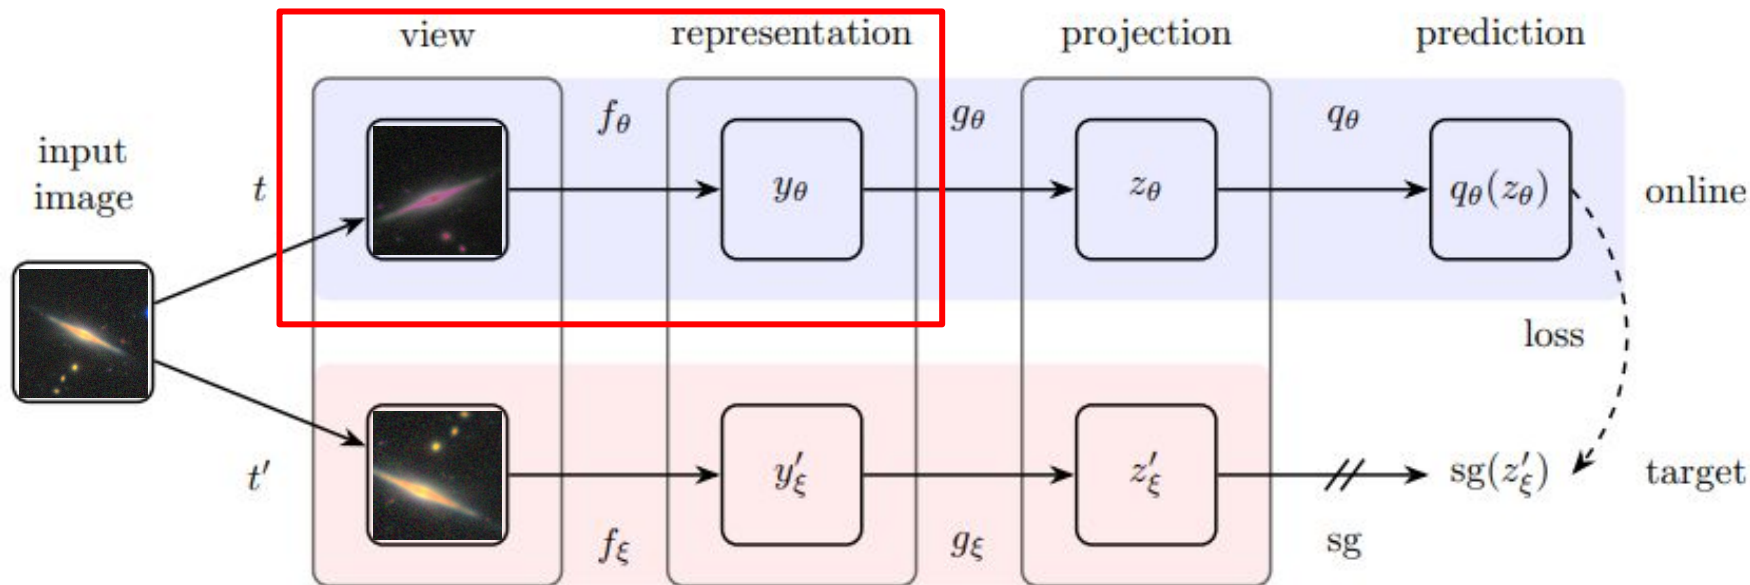


Figura 8. Arquitetura BYOL, adaptada de (Grill et al. 2020).

BYOL




Figura 8.1. Arquitetura BYOL, adaptada de (Grill et al. 2020).

BYOL





Gráfico 8. Loss do Cosseno no treino Auto Supervisionado do BYOL

Treino Auto Supervisionado

O BYOL aprende a partir da Loss do Cosseno entre os dois vetores de representação das imagens das duas redes (Online e Target).

Tempo de treino: 4 horas

BYOL




* Gap de generalização

Treino Supervisionado, sem Linear Probing

Nesse primeiro teste, treinamos a última camada da ResNet com um classificador novo, por 20 épocas.

BYOL



Treino Supervisionado com Linear Probing + Fine Tuning

Ajustamos o treino para 10 épocas com Linear probing, seguido com 10 épocas de Fine Tuning, com resultados muito melhores.

Gráficos 11 e 12. Loss (1) e Acurácia (2) dos conjuntos de treino e validação do BYOL, com fine tuning.

Tempo de treino: 45 minutos (Linear probing) + 45 minutos (Fine tuning)

BYOL

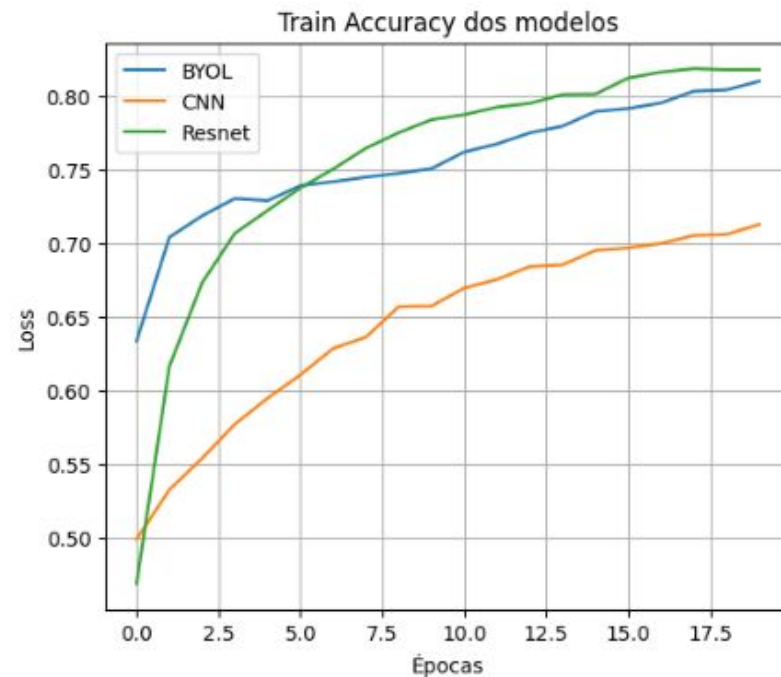

Resumo das etapas de treino

Etapa de Treino	Épocas	Loss	Tempo de treino	Learning Rate	Otimizador	Decay
Auto Supervisionado	40	Loss de Cosseno	4 horas e 30 minutos	1e-4	AdamW	1e-6
Linear Probing	10	CrossEntropy	45 minutos	1e-4	AdamW	1e-6
Fine Tuning	10	CrossEntropy	45 minutos	1e-5	AdamW	1e-4

Tabela 1 - Resumo das etapas de treino da arquitetura BYOL

Treinamento

Resnet-50 e BYOL tiveram melhor desempenho geral.



Gráficos 13 e 14. Loss (1) e Acurácia (2) dos conjuntos de treino e validação dos modelos estudados

Teste - Visão geral

Resnet-50 e BYOL tiveram melhor desempenho geral.




Gráfico 15. Acurácia Top-1 e Macro Recall Para os três classificadores no conjunto de teste.

Teste - Recall por classe

Classe	Modelo		
	CNN	Resnet-50	BYOL
0	0.22	0.33	0.43
1	0.75	0.91	0.82
2	0.90	0.97	0.94
3	0.84	0.92	0.88
4	0.66	0.78	0.62
5	0.66	0.82	0.75
6	0.71	0.75	0.73
7	0.61	0.52	0.61
8	0.86	0.88	0.92
9	0.89	0.95	0.94

Tabela 2 - *Recall* por classe para os três classificadores. Os valores destacados correspondem ao classificador com maior *recall* por classe.

Teste - Recall por classe




Gráfico 16.- Recall por classe dos três classificadores no conjunto de teste.

Teste - Matriz de confusão por classe

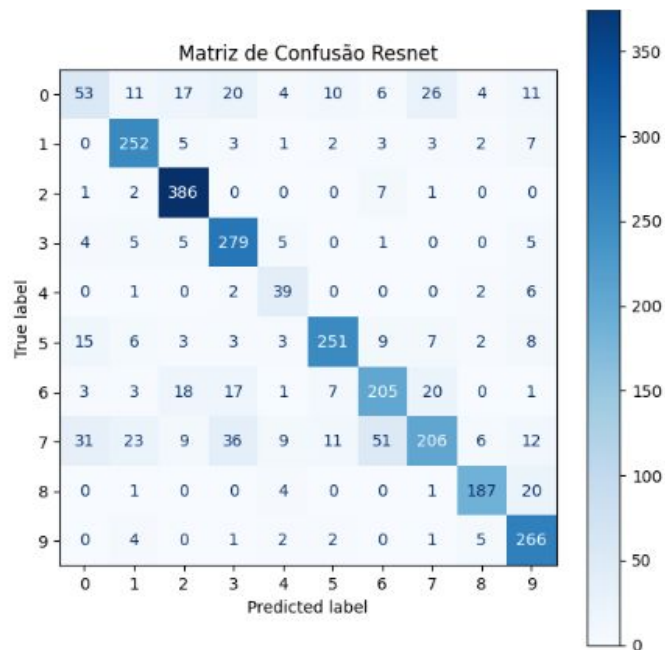


Gráfico 17. *Recall* por classe para os três classificadores. Os valores destacados correspondem ao classificador com maior *recall* por classe.




Figura 3. Exemplos de imagens do Galaxy10-DECaLS das diferentes classes do conjunto de dados.

Recall por classe - Comparativo

Comparação com resultados da literatura similares.

Le, Tram, et al

Classe	Modelo		
	CNN	Resnet-50	BYOL
0	0.22	0.33	0.43
1	0.75	0.91	0.82
2	0.90	0.97	0.94
3	0.84	0.92	0.88
4	0.66	0.78	0.62
5	0.66	0.82	0.75
6	0.71	0.75	0.73
7	0.61	0.52	0.61
8	0.86	0.88	0.92
9	0.89	0.95	0.94

Classe	Modelo		
	CNN	Resnet-50	Efficientnetb5
0	0.19	0.19	0.52
1	0.56	0.86	0.89
2	0.84	0.87	0.96
3	0.86	0.94	0.96
4	0.82	0.78	0.88
5	0.56	0.75	0.90
6	0.55	0.83	0.80
7	0.67	0.76	0.79
8	0.76	0.94	0.93
9	0.74	0.86	0.94

Tabelas 3 e 4 - *Recall* por classe para os três classificadores, comparado a literatura. Os valores destacados correspondem ao classificador com maior *recall* por classe.

Le, Tram, et al. "Enhanced comparative analysis of pretrained and custom deep convolutional neural networks for galaxy morphology classification." Engineering Proceedings 89.1 (2025): 36.

Conclusão

O trabalho explorou a classificação de galáxias a partir de características morfológicas com o uso de Redes Neurais.

Os modelos explorados neste trabalho apresentaram boa performance em acurácia, com recall superior a 0.75 na maioria das classes, com exceção das classes com morfologia de alta variabilidade. Os resultados alcançados foram comparáveis a estudos similares na literatura.

Dentre as arquiteturas estudadas, o modelo Resnet-50 apresentou os melhores resultados.

Referências

- Leung, H., & Bovy, J. (2018). *Galaxy10 Dataset*. Em astroNN (versão 1.0.0). Disponível em <https://astronn.readthedocs.io/en/latest/galaxy10.html>
- Castro, Mariana Teixeira de. *Redes Neurais Convolucionais Aplicadas a Identificação e Classificação de Galáxias* / Mariana Teixeira de Castro. – 2025.
- Slijepcevic, I. V., Scaife, A. M. M., Walmsley, M., Bowles, M., Wong, O. I., Shabala, S. S. & White, S. V. (2024). *Radio Galaxy Zoo: towards building the first multi-purpose foundation model for radio astronomy with self-supervised learning*. RAS Techniques and Instruments, 3(1), 19–32. doi:10.1093/rasti/rzad055
- Grill, J.-B., Strub, F., Altché, F., Tallec, C., Richemond, P. H., Buchatskaya, E., ... & Valko, M. (2020). *Bootstrap Your Own Latent (BYOL): A New Approach to Self-Supervised Learning*. In Proceedings of the 34th Conference on Neural Information Processing Systems (NeurIPS 2020).
- Mohale, K., et al. (2024). *Enabling unsupervised discovery in astronomical images*. MNRAS, 530(1), 1274–?
- Le, Tram, et al. *Enhanced comparative analysis of pretrained and custom deep convolutional neural networks for galaxy morphology classification*. Engineering Proceedings 89.1 (2025): 36.
- Parker, L. H., Qu, H., Shen, J., Smith, M. J., Stone, C., Walmsley, M., & Wu, J. F. (2024). *The Multimodal Universe: Enabling Large-Scale Machine Learning with 100 TB of Astronomical Scientific Data*. arXiv preprint arXiv:2412.02527.
- Prantzos, N. (2023). Galaxy. In: Gargaud, M., et al. *Encyclopedia of Astrobiology*. Springer, Berlin, Heidelberg. https://doi.org/10.1007/978-3-662-65093-6_4009
- Conselice, Christopher J. “The Evolution of Galaxy Structure Over Cosmic Time.” Annual Review of Astronomy and Astrophysics, vol. 52, no. 1, Aug. 2014, pp. 291–337. Crossref, <https://doi.org/10.1146/annurev-astro-081913-040037>.

Obrigado!

ESA/Hubble & NASA, O. Fox, L. Jenkins, S. Van Dyk, A. Filippenko, J. Lee and
the PHANGS-HST Team, D. de Martin (ESA/Hubble), M. Zamani (ESA/Hubble)

CNN

Random Crop: O problema do corte aleatório como Data Augmentation no nosso dataset



Figura 5. Representação do Random Crop

Foram aplicados outros augmentations como ColorJitter, GaussianBlur, Blur, HorizontalFlip, VerticalFlip, Rotation

CNN

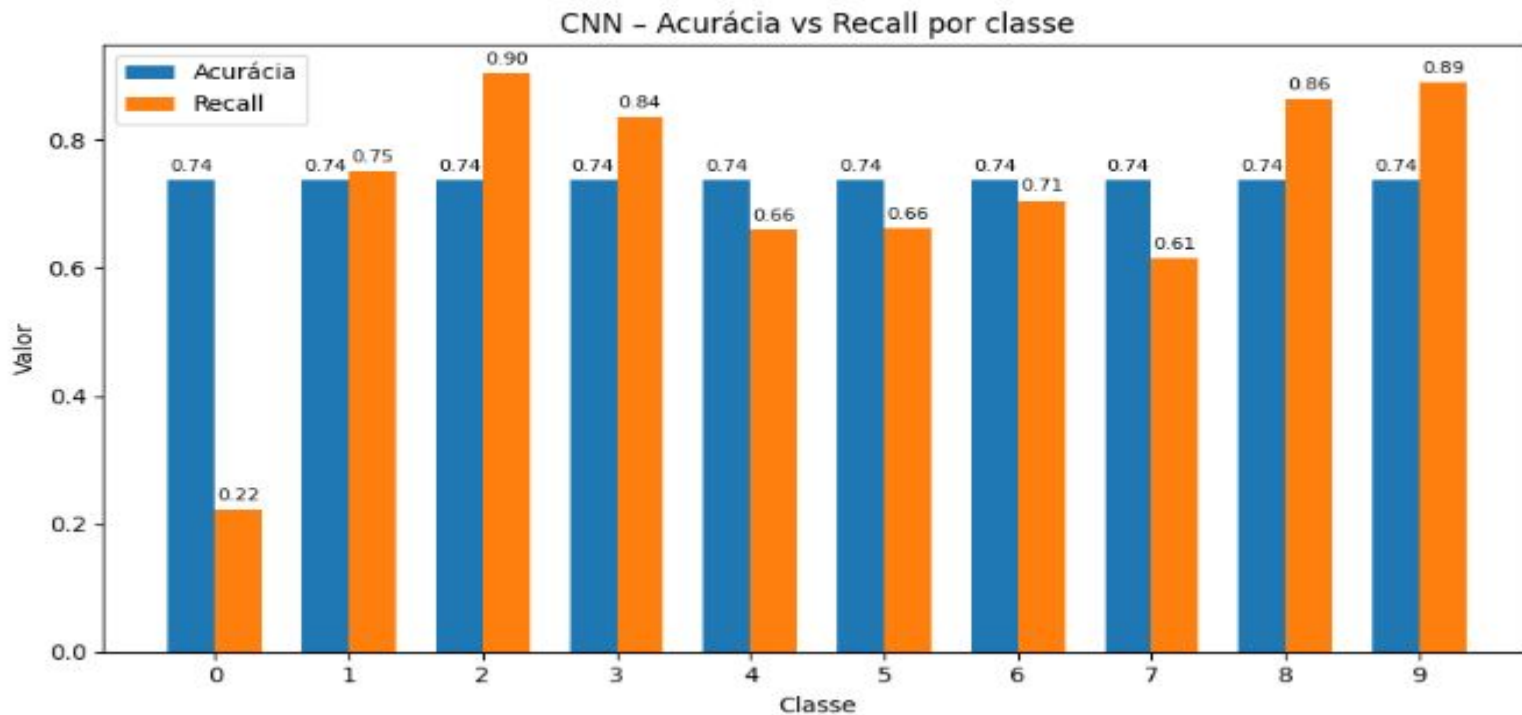
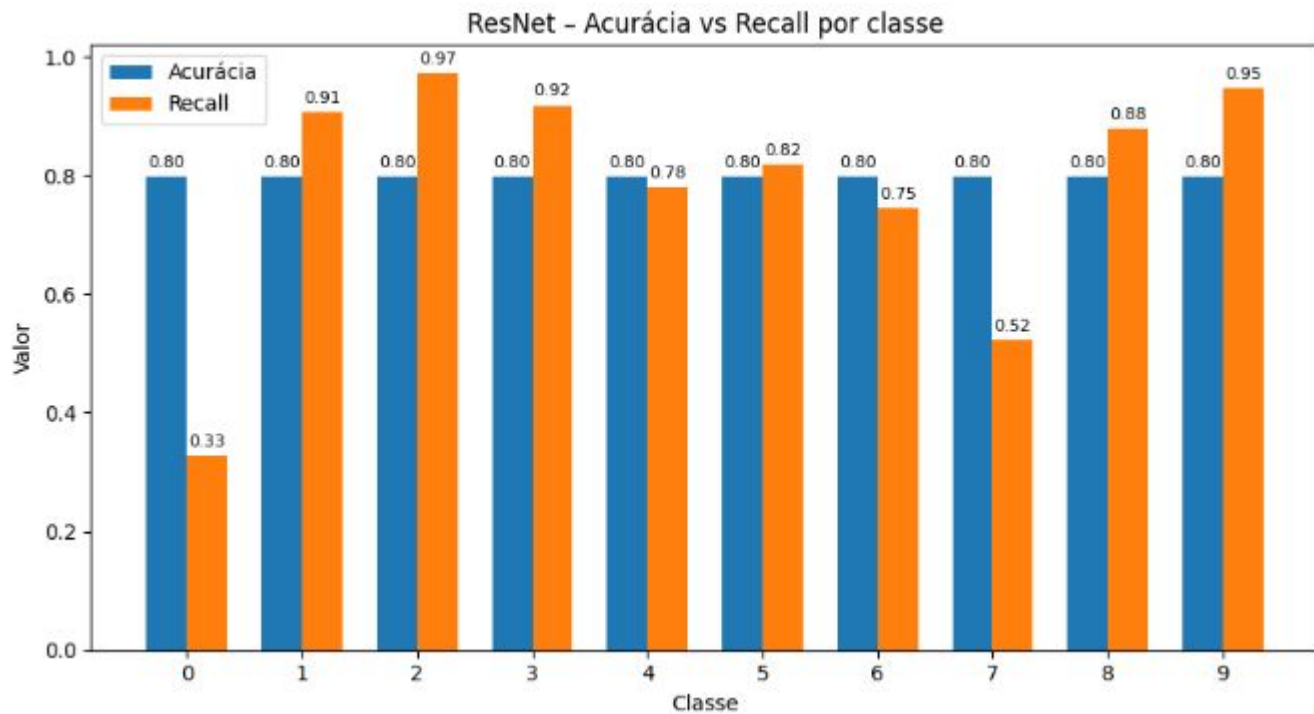


Gráfico 2. Acur

Tempo de treino: 35 minutos

ResNet-50




Tempo de treino: 1 hora e 30 minutos

Referências

- Conselice, Christopher J. "The Evolution of Galaxy Structure Over Cosmic Time." Annual Review of Astronomy and Astrophysics, vol. 52, no. 1, Aug. 2014, pp. 291–337. Crossref, <https://doi.org/10.1146/annurev-astro-081913-040037>.

Figura 1. Árvore de Decisão do *Galaxy Zoo*. Ferramenta que orienta a classificação de galáxias com base em suas características visuais.



Test loss CNN: 0.7555
 Test acc CNN: 0.7381

Precisão Média: 0.7440
 Recall Médio: 0.7381
 F1-score: 0.7311

Precisão por classe: [0.65454545 0.80384615 0.8196347 0.78395062 0.515625 0.87878788
 0.57910448 0.5627907 0.86792453 0.80128205]
 Recall por classe: [0.22222222 0.75179856 0.90428212 0.83552632 0.66 0.66123779
 0.70545455 0.6142132 0.86384977 0.88967972]

Classification Report:

	precision	recall	f1-score	support
0	0.65	0.22	0.33	162
1	0.80	0.75	0.78	278
2	0.82	0.90	0.86	397
3	0.78	0.84	0.81	304
4	0.52	0.66	0.58	50
5	0.88	0.66	0.75	307
6	0.58	0.71	0.64	275
7	0.56	0.61	0.59	394
8	0.87	0.86	0.87	213
9	0.80	0.89	0.84	281
accuracy			0.74	2661
macro avg	0.73	0.71	0.70	2661
weighted avg	0.74	0.74	0.73	2661

Test loss Resnet: 0.6230

Test acc Resnet: 0.7982

Precisão Média: 0.7928

Recall Médio: 0.7982

F1-score: 0.7882

Precisão por classe: [0.4953271 0.81818182 0.87133183 0.77285319 0.57352941 0.8869258
0.72695035 0.77735849 0.89903846 0.79166667]

Recall por classe: [0.32716049 0.90647482 0.97229219 0.91776316 0.78 0.81758958
0.74545455 0.52284264 0.87793427 0.94661922]

Classification Report:

	precision	recall	f1-score	support
0	0.50	0.33	0.39	162
1	0.82	0.91	0.86	278
2	0.87	0.97	0.92	397
3	0.77	0.92	0.84	304
4	0.57	0.78	0.66	50
5	0.89	0.82	0.85	307
6	0.73	0.75	0.74	275
7	0.78	0.52	0.63	394
8	0.90	0.88	0.89	213
9	0.79	0.95	0.86	281
accuracy			0.80	2661
macro avg	0.76	0.78	0.76	2661
weighted avg	0.79	0.80	0.79	2661

Test loss BYOL: 0.5857
 Test acc BYOL: 0.7914

Precisão Média: 0.7871
 Recall Médio: 0.7914
 F1-score: 0.7882

Precisão por classe: [0.50359712 0.88715953 0.85812357 0.82716049 0.67391304 0.76666667
 0.68474576 0.66298343 0.92488263 0.92013889]
 Recall por classe: [0.43209877 0.82014388 0.94458438 0.88157895 0.62 0.74918567
 0.73454545 0.60913706 0.92488263 0.9430605]

Classification Report:

	precision	recall	f1-score	support
0	0.50	0.43	0.47	162
1	0.89	0.82	0.85	278
2	0.86	0.94	0.90	397
3	0.83	0.88	0.85	304
4	0.67	0.62	0.65	50
5	0.77	0.75	0.76	307
6	0.68	0.73	0.71	275
7	0.66	0.61	0.63	394
8	0.92	0.92	0.92	213
9	0.92	0.94	0.93	281
accuracy			0.79	2661
macro avg	0.77	0.77	0.77	2661
weighted avg	0.79	0.79	0.79	2661

